Taller

Investigación del sector azucarero para el taller de Machine Learning

El objetivo de esta primera parte es comprender cómo funciona la producción de caña de azúcar en el Valle del Cauca y por qué sus características agrícolas, climáticas y productivas son importantes para construir modelos de regresión y clasificación para el Ingenio Providencia.

La investigación debe permitir justificar las variables utilizadas en los archivos , así como interpretar los resultados de los modelos desde una perspectiva agrícola y empresarial.

1. Importancia económica y social del sector azucarero

El cultivo de caña de azúcar es una de las actividades agroindustriales más representativas del Valle del Cauca. Su importancia no se limita a la producción de azúcar: también comprende la generación de empleo, la producción de etanol, el aprovechamiento de subproductos y el desarrollo de actividades de transporte, mantenimiento industrial y servicios agrícolas.

Entre sus principales aportes se encuentran:

- Empleo: genera puestos de trabajo directos e indirectos en labores agrícolas, cosecha, transporte, procesamiento industrial y comercialización.
- Desarrollo regional: impulsa la actividad económica de municipios del Valle del Cauca y del norte del Cauca.
- Producción agroindustrial: transforma la caña en azúcar y otros productos derivados, como etanol y energía a partir del bagazo.
- Encadenamientos productivos: demanda maquinaria, fertilizantes, servicios técnicos, logística y tecnologías para optimizar los cultivos.

Como referencia cuantitativa, el informe anual 2024-2025 de Asocaña presenta datos de 2023 según los cuales la agroindustria de la caña representó el 19,5 % del PIB agrícola y el 12,1 % del PIB industrial del Valle del Cauca. Para Colombia, las participaciones reportadas fueron del 2,3 % del PIB agrícola, 2,2 % del PIB industrial y 0,6 % del PIB total.

En cuanto al empleo, Asocaña ha reportado alrededor de 13 ingenios azucareros y una cadena productiva que incluye miles de cultivadores y empresas proveedoras. Sus cifras de empleo

varían según el año y la metodología utilizada, por lo que el informe debe indicar siempre la fecha de referencia

2. Factores que determinan el rendimiento de la caña

2.1. Toneladas de caña por hectárea (TCH)

El indicador TCH mide la cantidad de caña cosechada por cada hectárea cultivada. Por ejemplo, un rendimiento de 100 TCH significa que se obtuvieron 100 toneladas de caña en una hectárea.

Los principales factores que pueden afectar este indicador son:

Factor	Influencia sobre el TCH
Lluvias y temperatura	Determinan la disponibilidad de agua y las condiciones para el crecimiento. El exceso de lluvia también puede dificultar la cosecha.
Tipo y fertilidad del suelo	Afectan la disponibilidad de nutrientes, el drenaje y el desarrollo de las raíces.
Variedad de caña	Cada variedad tiene características particulares de crecimiento, adaptación climática y resistencia a enfermedades.
Edad del cultivo	Influye en el tiempo disponible para desarrollar tallos y acumular biomasa antes de la cosecha.
Número de cortes	Las socas sucesivas pueden presentar rendimientos distintos a los del cultivo inicial, llamado plantilla.
Riego	Ayuda a suplir las necesidades de agua durante periodos secos.
Fertilización	Permite aportar nutrientes como nitrógeno, fósforo y potasio según las necesidades del cultivo.
Manejo agrícola	Incluye control de malezas y plagas, drenaje, preparación del suelo y planificación de la cosecha.

La evidencia regional confirma que las lluvias, la edad de cosecha y el manejo del cultivo son variables relevantes. Por ejemplo, Cenicaña señaló que durante parte de 2022 y 2023 muchas suertes fueron cosechadas antes de los 12 meses y que las lluvias excesivas afectaron tanto la productividad como la logística de cosecha.

Esto explica por qué la variable lluvias es relevante para un modelo predictivo. Sin embargo, su efecto no necesariamente es lineal: la falta de agua puede limitar el crecimiento, mientras que un exceso puede perjudicar el cultivo o dificultar las operaciones.

2.2. Porcentaje de sacarosa (%Sac.Caña)

El porcentaje de sacarosa indica la concentración de sacarosa presente en la caña y sirve como indicador de su calidad azucarera. No debe confundirse con el TCH: una suerte puede producir muchas toneladas de caña sin tener necesariamente una concentración alta de sacarosa.

Los factores más importantes son:

- Maduración: durante esta etapa la planta acumula sacarosa en los tallos. La edad ayuda a contextualizar el proceso, pero no determina por sí sola la concentración final.
- Variedad: existen diferencias genéticas en la capacidad de acumular azúcar y en el comportamiento de maduración.
- Clima: la lluvia, la temperatura y las condiciones ambientales durante el ciclo pueden modificar el crecimiento y la acumulación de sacarosa.
- Disponibilidad de agua: tanto el déficit como el exceso pueden alterar el desarrollo de la planta y su maduración.
- Manejo agronómico: la fertilización, el riego y la programación de la cosecha pueden influir en la calidad obtenida.

Un estudio publicado en Acta Agronómica examinó las asociaciones entre características agronómicas, TCH y sacarosa en variedades evaluadas en el valle geográfico del río Cauca. Sus resultados respaldan la importancia de considerar conjuntamente las características del cultivo y su ambiente

3. Características del Ingenio Providencia y sostenibilidad

El Ingenio Providencia forma parte de la agroindustria de la caña del Valle del Cauca. Su operación conecta las actividades agrícolas con la transformación industrial de la caña y la producción de azúcar y otros productos derivados.

Para documentar sus características específicas, conviene consultar los informes corporativos oficiales, en particular el Informe de Sostenibilidad 2024 de Ingenio Providencia. La empresa publica informes de varios años que permiten revisar sus avances ambientales, sociales y económicos.

1. Gestión ambiental. Las prácticas relacionadas con el agua, la fertilización, el suelo, los residuos y la biodiversidad pueden influir en las condiciones de producción y en la sostenibilidad de los cultivos.

2. Tecnología agrícola. Los sistemas de monitoreo, la planificación de cosechas y el análisis de datos pueden mejorar la gestión de las suertes y ayudar a identificar diferencias de rendimiento.

3. Sistemas de producción. No se debe asumir que todos los cultivos del ingenio son orgánicos o que se manejan de la misma manera. Para afirmar que una parcela es orgánica, convencional o utiliza una práctica específica, se necesita evidencia del informe corporativo o de los datos proporcionados.

4. Estado del arte: Machine Learning aplicado a la agricultura

El Machine Learning permite identificar relaciones entre variables agrícolas y resultados productivos mediante el análisis de datos históricos. En agricultura de precisión se utiliza para estimar rendimientos, anticipar problemas, optimizar recursos y apoyar decisiones de manejo.

Una revisión sistemática publicada en 2025 sobre predicción del rendimiento de la caña de azúcar mediante sensores remotos y Machine Learning identificó 47 estudios para análisis detallado. Entre las variables más utilizadas aparecen la temperatura, las precipitaciones, la evapotranspiración y el número de cortes. Los algoritmos más frecuentes incluyen Random Forest y regresión lineal múltiple.

Otra revisión, publicada en 2025 en Smart Agricultural Technology, identificó la temperatura, el tipo de suelo y la vegetación entre las variables más empleadas para predecir rendimientos agrícolas. También destacó la regresión lineal, Random Forest y Gradient Boosting entre los algoritmos de Machine Learning más utilizados

Modelos que podrían utilizarse en el taller

Modelo	Aplicación	Ventaja principal
Regresión lineal	Predecir TCH y %Sac.Caña	Fácil de interpretar y utilizar como referencia inicial.
Árbol de decisión	Regresión y clasificación	Permite representar reglas de decisión comprensibles.
Random Forest	Regresión y clasificación	Captura relaciones no lineales y combina múltiples árboles.
Gradient Boosting	Regresión y clasificación	Puede lograr buenas predicciones al combinar árboles de manera secuencial.
K-Nearest Neighbors (KNN)	Regresión y clasificación	Utiliza registros similares para estimar resultados.

No existe un algoritmo que sea siempre el mejor. El desempeño depende de la cantidad y calidad de los datos, de las variables disponibles, del ruido y de la forma en que se evalúa cada modelo.

¿Cómo evaluar los modelos de regresión?

- MAE: error absoluto medio; indica cuánto se equivoca el modelo en promedio, en las unidades de la variable.
- RMSE: penaliza más los errores grandes.
- R^2: mide qué proporción de la variabilidad del objetivo explica el modelo, de acuerdo con la definición habitual de esta métrica.

Se recomienda comparar una regresión lineal básica con al menos un modelo basado en árboles. La selección final debe depender de los resultados sobre datos de prueba que no se utilizaron para entrenar los modelos.

5. Aplicación al problema de clasificación

En la segunda parte del taller se busca transformar los valores continuos de TCH y %Sac_caña en tres categorías: alto, medio y bajo.

Esto convierte dos problemas de regresión en dos problemas de clasificación.

Por ejemplo, un registro que tenga un TCH de 110 podría pertenecer a la categoría «alto», dependiendo de los límites definidos para clasificar los datos.

¿Cómo definir las categorías?

Hay dos métodos principales:

Método 1. Rangos basados en conocimiento agronómico

Se establecen límites respaldados por estudios del sector o por criterios técnicos. Es útil cuando se desea que las categorías representen niveles productivos con significado agrícola.

Método 2. Rangos basados en la distribución de los datos

Se utilizan terciles o cuantiles para dividir los registros en tres grupos de tamaños aproximadamente iguales. Es práctico cuando no se conocen límites agronómicos apropiados.

Si el taller no proporciona umbrales específicos, se pueden utilizar terciles como punto de partida:

- Bajo: valores inferiores o iguales al percentil 33,3.
- Medio: valores entre los percentiles 33,3 y 66,7.
- Alto: valores superiores al percentil 66,7.

Modelos y métricas para clasificación

Las métricas principales son:

- Accuracy: proporción de predicciones correctas.
- Precision: proporción de predicciones positivas de una clase que realmente pertenecen a ella.
- Recall: proporción de registros de una clase que el modelo identifica correctamente.
- F1-score: combina precision y recall.
- Matriz de confusión: permite observar qué categorías se confunden entre sí.

En este caso, conviene revisar especialmente si el modelo confunde los niveles medios con los altos o bajos, porque esto ayuda a comprender los errores de clasificación.

6. Relación entre la investigación y los archivos del taller

La siguiente tabla resume cómo se conecta la investigación con las variables y los modelos.

Variable o elemento	Justificación	Aplicación
lluvias	Influye en la disponibilidad de agua, el crecimiento y las operaciones de cosecha.	Regresión y clasificación.
variedad	Las variedades presentan diferencias de adaptación, productividad y maduración.	Regresión y clasificación.
edad	Ayuda a caracterizar el desarrollo del cultivo al momento de la cosecha.	Regresión y clasificación.
cortes	Permite distinguir la plantilla de las socas y estudiar cambios de productividad.	Regresión y clasificación.
TCH	Mide la productividad agrícola por hectárea.	Variable objetivo de regresión y clasificación.
%sacCaña	Representa un indicador de la calidad azucarera de la caña.	Variable objetivo de regresión y clasificación.

La disponibilidad real de estas variables debe verificarse en cada archivo. No se debe asumir que los dos conjuntos contienen las mismas columnas ni que sus registros pueden relacionarse directamente.